
LG 헬로=이전 DX DATA 스쿨 2기

AI 기반 셋톱박스 장애 사전 감지 및 경고 시스템

PREDICT HUNHERS

이민형 김재희 이정호 황현숙 조은빈

팀 소개

이민형

PM
Backend
Data Analysis

김재희

Backend
Data Analysis

이정호

Data Analysis

황현숙

Data Analysis

조은빈

DB
Data Analysis

목차

01

프로젝트 소개

- 프로젝트 배경
- 프로젝트 목적

02

프로젝트 개요

- 문제 및 요구사항 정의

03

프로토타입

- 주요기능
- 시연 영상

04

데이터 분석

- 데이터 분석 배경
- 데이터 전처리 및 EDA
- 모델링

05

시각화

- 이상탐지 알림 웹 서비스 및 대시보드

06

결론

- 기대 효과
- 추후 개선 사항
- 소감

프로젝트 배경

이상화면 발생 빈도

구분		이상화면 발생빈도(회)		
		전체 평균	뉴스	드라마
2022	소계	0.14	0.13	0.16
	LG 헬로비전	0.09	0.10	0.09
2023	소계	0.19	0.21	0.23
	LG 헬로비전	0.29	0.35	0.23

셋톱박스 성능 이용자 만족도

구분		셋톱박스 성능 이용자 만족도 (점)		
		평균	내 편의성	조작 용이성
2022	평균	60.3	61.9	59.3
	LG 헬로비전	61.2	61.3	60.3
2023	평균	58.0	58.0	58.1
	LG 헬로비전	57.9	59.0	57.0

이상화면 발생 빈도 증가

전년도에 비해 이상화면 발생 비율 **3배** 증가
전년도 대비 상승한 평균 이상의 발생 빈도

이용자 만족도 하락

이용자 만족도 전년도 대비 하락
평균 이하의 만족도로 전년도 대비 하락

프로젝트 목적

기존 고객 이탈 방지 및 수익 손실 감소

- 사전 교체 시스템 도입

AI 기반 장애 패턴 감지를 통한 조기 경보 솔루션을 제공해 이상이 감지된 셋톱박스를 **사전에 교체**하여, 고객의 불편 최소화

헬로=전 사내 업무 효율 증대

- 실시간 시각화 대시보드 제공

현재 셋톱박스 상태를 **실시간으로 시각화**하여 직접 확인 가능

- 사전 알림 시스템 구축

오류가 발생하기 전에 관리자에게 **e-mail로 알림**을 제공하여, 사전에 문제를 인지하고 대응 가능

문제 및 요구사항 정의

01 문제상황

- 현재 시스템은 장애 예측 및 대응이 어려움
- 셋톱박스 데이터 실시간 모니터링, 장애 예측 필요
- 장애 발생 가능성 높을 시 사전 알림 시스템 필요

02 요구사항 정의

장애 발생 확률 예측


셋톱박스 데이터 분석을 통해 장애가 발생하기 전 장애 예측

예측값이 임계값을 넘어갔을 경우 알림 발송

셋톱박스 데이터를 바탕으로 장애가 발생할 시 알림을 주는 웹 개발

주요 기능

셋톱박스 데이터 모니터링



실시간 셋톱박스 이상 탐지 알림 서비스

실시간 셋톱박스 이상 탐지 알림 서비스

날짜 (연-월-일):

연도-월-일

임계값 (default: 0.033):

시간 배속 (1~1000배):


1

탐지 시작

셀번호:

대시보드 불러오기

시연 영상



데이터 분석 배경

이슈	> 해결방안
1. 데이터 부족 현업에서도 데이터가 부족한 상황에서도 결론을 내야 하는 경우가 있음 2. 데이터 불균형 이상탐지에서는 정상 데이터만 많고 고장 데이터가 별로 없는 경우가 빈번함	1. 이용 가능한 최선의 정보 사용 가용 가능한 피쳐 추가 2. 소규모 테스트 검증 실제 데이터의 작은 규모로 먼저 시도하여 결과를 확인하고, 이를 통해 결정의 타당을 검증 3. 교차 검증으로 리스크 최소화 OOF로 여러 번 학습을 시킨 다음 모델의 예측을 평균하여 최종 예측값을 결정

데이터 전처리 및 EDA

데이터 전처리

- 1. 기본 가이드라인에 따른 처리: 상향파워 1 제거
- 2. 결측치 처리
- 3. 클라우드 환경에서 데이터 로딩
 - a. 클라우드 환경을 통해 데이터 접근성 향상
 - b. 데이터 적재에 훨씬 더 용이한 S3 이용
- 4. 측정 시간: 일, 시, 분, 요일로 분리하여 컬럼 추가

	측정시간	온오프라인여부	상향파워1	상향파워2	상향SNR	하향파워	하향SNR	셀번호
0	2024-04-01 00:40:00	online	0.0	34.0	34.0	6.0	37.0	YSDG0009
1	2024-04-01 01:00:00	online	0.0	0.0	18.0	0.0	0.0	YSDG0009
2	2024-04-01 01:30:00	offline	NaN	NaN	NaN	NaN	NaN	YSDG0009
3	2024-04-01 01:30:00	online	1.0	47.0	36.0	-2.0	38.0	YSDG0009
4	2024-04-01 01:40:00	online	-5.0	46.0	27.0	-2.0	37.0	YSDG0009
5	2024-04-01 01:40:00	online	1.0	47.0	32.0	-2.0	38.0	YSDG0009
6	2024-04-01 01:45:00	online	0.0	0.0	33.0	0.0	0.0	YSDG0009
7	2024-04-01 01:45:00	online	-1.0	51.0	32.0	-4.0	36.0	YSDG0009
8	2024-04-01 01:45:00	online	1.0	47.0	36.0	-2.0	38.0	YSDG0009
9	2024-04-01 02:00:00	online	0.0	47.0	33.0	1.0	37.0	YSDG0009
10	2024-04-01 02:00:00	online	0.0	51.0	31.0	-2.0	37.0	YSDG0009
11	2024-04-01 02:10:00	online	0.0	40.0	33.0	0.0	37.0	YSDG0009
12	2024-04-01 02:10:00	online	0.0	43.0	35.0	0.0	38.0	YSDG0009

객체 (5) 정보

S3 URI 복사

URL 복사

다운로드

열기

삭제

작업

폴더 만들기

업로드

객체는 Amazon S3에 저장되어 있는 기본 엔티티입니다. Amazon S3 인벤토리 [링크](#)를 사용하여 버킷에 있는 모든 객체의 목록을 얻을 수 있습니다. 다른 사용자가 객체에 액세스할 수 있게 하려면 명시적으로 권한을 부여해야 합니다. [자세히 알아보기](#)

Q

접두사로 객체 찾기

<

1

>


☐	이름	유형	마지막 수정	크기	스토리지 클래스
☐	장애내역.csv	csv	2024. 6. 20. pm 11:17:27 PM KST	8.7KB	Standard
☐	avail_data.csv	csv	2024. 6. 20. pm 11:17:29 PM KST	14.5MB	Standard
☐	data_with_lags.csv	csv	2024. 6. 20. pm 11:17:26 PM KST	34.0MB	Standard
☐	filtered_data.csv	csv	2024. 6. 20. pm 11:17:27 PM KST	1.0MB	Standard
☐	settop.csv	csv	2024. 6. 20. pm 11:17:26 PM KST	154.1MB	Standard

PREDICT –UNTERS

10

데이터 전처리 및 EDA

데이터 분포 확인




다른 피쳐에 비해 상향 SNR과 cum_rate의 중앙값이 장애 여부에 따라 다르게 위치함

데이터 전처리 및 EDA

데이터 분포 확인

1. 데이터의 균형을 모두 맞추고 분석

2. 불균형한 데이터에 적합한 모델 선택



데이터 전처리 및 EDA

새로운 컬럼 추가

	상향파워2	상향SNR	하향파워	하향SNR	셀번호	cum_rate	장애여부	일	시	분	하향파워_lag1	하향파워_lag2	하향파워_lag3	하향파워_lag4	하향파워_lag5	하향SNR_lag1	하향SNR_lag2	하향SNR_lag3	하향SNR_lag4	하향SNR_lag5
0	53.000000	39.000000	-6.000000	32.000000	5	0.333333	0	1	1	30	-6.000000	3.000000	2.000000	-3.000000	-3.000000	31.000000	38.000000	38.000000	35.500000	35.500000
1	43.500000	30.500000	5.500000	42.000000	6	0.500000	0	1	1	30	10.000000	10.000000	13.000000	-3.000000	0.666667	41.000000	41.000000	45.000000	41.000000	42.333333
2	43.000000	35.000000	2.000000	32.000000	4	0.666667	0	1	1	30	2.333333	1.000000	2.333333	-2.000000	-1.250000	35.333333	39.000000	34.333333	34.000000	36.000000
3	41.454545	28.818182	-0.272727	37.181818	2	1.000000	0	1	1	30	-1.400000	-1.846154	-2.466667	-2.000000	-1.727273	36.866667	36.615385	36.200000	36.700000	36.636364
4	43.000000	24.000000	1.000000	38.000000	8	0.666667	0	1	1	30	0.000000	4.250000	11.000000	-4.000000	-4.000000	36.666667	37.750000	39.000000	36.000000	38.000000
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
95248	37.000000	29.000000	-5.000000	41.000000	3	0.389346	0	1	23	0	-7.000000	-5.000000	15.000000	-8.000000	-5.000000	38.000000	39.000000	36.000000	41.000000	41.000000
95249	39.866667	28.600000	-1.666667	37.866667	2	0.971907	0	1	23	0	-1.416667	-1.800000	-3.333333	-4.666667	-1.500000	37.750000	37.500000	38.333333	37.666667	37.500000
95250	43.500000	30.500000	-12.000000	35.500000	9	0.460993	0	1	23	0	2.000000	1.000000	-11.000000	-11.000000	-12.000000	38.000000	38.000000	34.000000	34.000000	35.500000
95251	35.000000	34.000000	-5.000000	38.000000	4	0.378733	0	1	23	0	-6.000000	-2.000000	-2.000000	-5.000000	-4.000000	39.333333	38.500000	38.000000	38.000000	39.000000
95252	40.000000	28.000000	-3.000000	38.500000	9	0.479284	0	1	23	0	-1.000000	-2.333333	-2.500000	-2.500000	-4.000000	39.000000	39.000000	39.000000	39.000000	39.000000

1. 컬럼 cum_rate 추가

- 동일한 시간에 하나의 셋톱박스에서 Log가 여러 번 발생
- total_num = 셋톱박스 별 존재하는 측정시간의 개수
- cum_num = 중복된 측정시간의 개수
- **cum_rate = cum_num / total_num**

2. lag 값이 있는 컬럼 추가

- 특정 시점의 데이터를 이전 시점의 데이터와 비교
- t시점 데이터에서 lag = 1 이면 t-1 시점의 데이터

모델링

모델 선정


```

장애여부
0      95613
1       132
Name: count, dtype: int64

```

- 모델 리스트

1. XGBoost Classifier
2. Logistic Regression
3. SVM
4. RandomForest Classifier
5. CatBoost



- Stratify

데이터 샘플링 시 각 클래스가 원본 데이터에서 나타나는 비율을 유지하도록 데이터를 나누는 방법
→ 모델의 성능 향상

모델링


모델 학습 데이터

- **셋톱박스 일부 데이터 제외**
 - 장애가 있는 셋톱박스의 데이터만 사용하여 모델을 학습
- **셀번호 컬럼 제외**
 - 과적합 방지
 - 셀번호의 포함 여부가 모델의 성능에 영향을 주지 않음

모델링

모델 성능 비교

Logistic Regression




```
Best Threshold: 0.009
Best F1 Score: 0.0190
```

	precision	recall	f1-score	support
0	1.00	0.99	0.99	19025
1	0.01	0.08	0.02	26
accuracy			0.99	19051
macro avg	0.50	0.53	0.51	19051
weighted avg	1.00	0.99	0.99	19051

ROC : 0.65

SVM




```
Best Threshold: 0.002
Best F1 Score: 0.0071
```

	precision	recall	f1-score	support
0	1.00	0.94	0.97	19025
1	0.00	0.15	0.01	26
accuracy			0.94	19051
macro avg	0.50	0.55	0.49	19051
weighted avg	1.00	0.94	0.97	19051

ROC : 0.56

RandomForest Classifier




```
Best Threshold: 0.060
Best F1 Score: 0.0556
```

	precision	recall	f1-score	support
0	1.00	1.00	1.00	19025
1	0.04	0.08	0.06	26
accuracy			1.00	19051
macro avg	0.52	0.54	0.53	19051
weighted avg	1.00	1.00	1.00	19051

ROC : 0.64

CatBosst Classifier




```
Best Threshold: 0.014
Best F1 Score: 0.1064
```

	precision	recall	f1-score	support
0	1.00	1.00	1.00	19025
1	0.07	0.19	0.11	26
accuracy			1.00	19051
macro avg	0.54	0.59	0.55	19051
weighted avg	1.00	1.00	1.00	19051

ROC : 0.66

모델링

모델 성능 비교



```
Best Threshold: 0.038
Best F1 Score: 0.1290
```


	precision	recall	f1-score	support
0	1.00	1.00	1.00	19025
1	0.11	0.15	0.13	26
accuracy			1.00	19051
macro avg	0.55	0.58	0.56	19051
weighted avg	1.00	1.00	1.00	19051

XGboost Classifier

ROC : 0.77

모델링

모델 성능 향상 : OOF




- **OOF(Out Of Fold)**

OOF 예측은 교차 검증을 통해 모델의 일반화 성능을 정확하게 평가하고,
다양한 모델의 장점을 결합하여 앙상블 학습의 최종 예측 성능을 향상시킴

모델링

모델 성능 향상 : OOF





```
Best Threshold: 0.038
Best F1 Score: 0.1290
      precision    recall  f1-score   support

      0       1.00      1.00      1.00    19025
      1       0.11      0.15      0.13         26

 accuracy          1.00          1.00    19051
 macro avg       0.55      0.58      0.56    19051
 weighted avg    1.00      1.00      1.00    19051
```

OOF 사용 전
ROC : 0.77



```
Best Threshold: 0.031
Best F1 Score: 0.0681
      precision    recall  f1-score   support

      0       1.00      1.00      1.00    95123
      1       0.05      0.10      0.07         130

 accuracy          1.00          1.00    95253
 macro avg       0.53      0.55      0.53    95253
 weighted avg    1.00      1.00      1.00    95253
```

OOF 사용 후
ROC : 0.81

데이터 분석 결과

예측 결과

4/18 예측 결과

상향파워2	상향SNR	하향파워	하향SNR	cum_rate	일	시	분	요일	상향파워2_lag1	...	하향파워_lag5	하향SNR_lag1	하향SNR_lag2	하향SNR_lag3	하향SNR_lag4	하향SNR_lag5	측정시간	실제장애여부	장애여부	장애확률
50.000000	35.000000	1.000000	37.000000	0.352941	18	2	5	3	48.500000	...	8.000000	40.500000	38.000000	35.000000	37.000000	39.000000	2024-04-18 02:05:00	1	1	0.541531
39.500000	29.833333	-8.000000	29.000000	0.637097	18	2	45	3	42.000000	...	3.000000	40.000000	39.000000	39.000000	38.000000	39.000000	2024-04-18 02:45:00	1	1	0.485108
35.500000	35.000000	5.500000	39.500000	0.312312	18	2	25	3	34.000000	...	-9.000000	40.000000	40.000000	39.500000	38.000000	38.000000	2024-04-18 02:25:00	1	1	0.482884
44.833333	35.666667	0.500000	40.333333	0.037037	18	2	15	3	40.000000	...	1.000000	38.000000	41.000000	40.000000	41.000000	41.000000	2024-04-18 02:15:00	1	1	0.459484
35.000000	30.000000	1.000000	38.000000	0.096408	18	2	15	3	35.000000	...	-1.000000	38.000000	43.000000	38.000000	38.000000	37.000000	2024-04-18 02:15:00	1	1	0.441995
37.250000	33.750000	11.750000	39.500000	0.223150	18	2	15	3	51.000000	...	2.000000	38.000000	36.000000	37.000000	36.000000	38.000000	2024-04-18 02:15:00	1	1	0.415962
42.000000	36.000000	3.000000	39.000000	0.061927	18	2	15	3	43.000000	...	10.000000	40.000000	40.000000	40.000000	39.000000	40.000000	2024-04-18 02:15:00	1	1	0.377493
51.000000	36.000000	3.000000	35.000000	0.010309	18	2	15	3	51.000000	...	2.000000	35.000000	35.000000	35.000000	35.000000	35.000000	2024-04-18 02:15:00	1	1	0.358155
44.000000	36.000000	2.800000	39.000000	0.308661	18	2	25	3	46.000000	...	-4.000000	38.000000	38.000000	38.000000	38.000000	38.000000	2024-04-18 02:25:00	1	1	0.334843
39.000000	32.000000	15.000000	40.000000	0.271493	18	2	25	3	38.000000	...	8.000000	40.000000	40.000000	37.000000	37.000000	37.000000	2024-04-18 02:25:00	1	1	0.330894

- 모델이 예측한 장애 여부와 장애 확률 컬럼 추가한 결과 출력
- 장애 예측 확률이 높은 경우 실제로 장애 상태임을 확인 가능

이상탐지 알림 웹 서비스 및 대시보드

● 이상 탐지 시 메일 알림

- 임계값 이상의 확률 탐지 시 관리자 email로 메일 발송

● 장애 시점 표시

- 경고가 온 셋톱박스의 이전 하루치의 데이터 값을 불러오는 대시보드 확인

● 셋톱박스 데이터 모니터링

- 각 피쳐의 시계열 그래프 확인

실시간 셋톱박스 이상 탐지 알림 서비스

날짜 (연-월-일):
2024-04-18

임계값 (default: 0.033):
0.033

시간 배속 (1~1000배):
60

탐지 시작

실시간 이상 탐지를 수행 중입니다.
탐지에는 약 1~2분 정도 소요됩니다.

장애헤생 경고! 시간: 2024-04-18 00:25:00 셀번호: YSHS0011 장애 확률: 0.038411758840084076
장애헤생 경고! 시간: 2024-04-18 00:35:00 셀번호: YSHS0079 장애 확률: 0.034459926187992096
장애헤생 경고! 시간: 2024-04-18 00:55:00 셀번호: YSHS0036 장애 확률: 0.058152005076408386
장애헤생 경고! 시간: 2024-04-18 01:05:00 셀번호: YSHS0036 장애 확률: 0.03418583795428276

셀번호:


대시보드 불러오기

☆ 장애 발생 경고

보낸사람 predicthunter1@naver.com

2024년 6월 21일 (금) 오후 5:52

장애헤생 경고!
장애헤 확률: 0.04, 셀번호: YSDG10-1, 시간: 2024-04-18 03:35:00
현재 상태 상황파워2 : 52.5, 상황SNR : 21.5, 하향파워 : 0.0, 하향SNR : 39.0



기대효과

1. 셋톱 박스의 이상 패턴을 기반으로 장애 예측이 가능한 시스템 개발

- 셋톱박스 데이터 모니터링을 통해 서비스 중단을 최소화하고 사용자 만족도를 높일 수 있음
- 장애를 미리 예측하고 예방함으로써, 긴급 유지보수의 빈도를 줄이고 장기적으로 유지보수 비용 절감

2. 품질 경쟁력 있는 시스템으로 MSO 시장 선도

- AI 기반의 스마트 유지보수 시스템이 차별화 요소가 되어 시장에서의 경쟁력을 강화
- 안정적인 서비스 제공으로 인한 고객의 신뢰도 향상

3. 고령층과 같은 정보취약계층에 도움이 되는 서비스 개발

- 정보 취약 계층에게도 안정적인 서비스 제공을 통해 디지털 격차를 해소하는 데 기여
- 복잡한 as접수 과정 없이 사전 점검을 통해 고령층이나 기술에 익숙하지 않은 사용자의 이용자 경험 향상 가능


추후 개선 사항

클라우드 시스템을 이용한 실시간 자동화

클라우드 시스템을 통해 자동화 하면, 실시간으로 알림 및 대시보드 활용이 가능 및 모델 지속적 업데이트 가능

데이터 소스 확장

더 많은 데이터를 수집하여 분석 정확성 향상



협업 방식 소개

aws

5월 23일 목요일

5월 24일 금요일

5월 25일 토요일

이정호 오전 10:31

설계도에 AWS lambda에 데이터 전처리가 올라가는 것 처럼 DB도 AWS 어떤 서비스 안에 올라가는거 아닌가요?? 그러면 설계도에 DB가 아니라 AWS 서비스가 나오고 그 안에 DB내용이 들어가야 할 거 같아서 질문 드립니다!!

1개의 댓글 28일 전

이민형 오전 1:29

시각화 과정 Tableau로 수정, 5/24 DB 구축 토대로 설계도 수정

2개 파일

PH_AWS설계도_2차.drawio.png

PH_AWS설계도_2차.drawio

김재희 오전 11:31

S3 버킷에 초기데이터(새로운 로그데이터) (1번 버킷) > 람다 이벤트 호출 전처리 > S3 버킷에 전처리 된 데이터 저장 (2번 버킷) >

- EC2 서버 (훈련용 - 데이터 들어오면 훈련)
- Lambda 활용 훈련
- 세이지 메이커 활용 훈련 (엄청나게 비싸다)

> S3 버킷에 저장 (3번 버킷)

S3 쿼리 기능으로 원하는 셀번호의 값을 변수처리 후 쿼리된 결과를 시각화 호출 or DB 활용하여 호출

슬랙

PredictHunters

홈

공지

- 불만은 공적으로 말하기
- 이해 X 시, 바로바로 말하기
 - 이해하는 척 하다 걸리면 스벅 싸야함
- 집중 타임에 집중하기 → 딴짓하다 걸리면 집 사줘야 함
- 일정 미리 공유하기 (ex. 토요일 4시-7시 약속)
 - 4명 이상 만나서 결정된 사항에는 이의 제기 X, 무조건 따르기
- 싸우지 말기
- 만나게 될 시 만나는 장소는 사당
 - 가급적 만나지 말자

참고

- 데이터 분석 공부 자료
- 개인정보
- 일정 공유
- AWS 공동계정
- 발표자료

노션

회의

회의 캘린더 유형별 리:

셋탑 데이터 전처리

4/8 회의

4/8 회의

4/19 회의

4/23 회의

4/26 회의

4/30 회의

5/3 회의

5/8 회의

5/10 회의

5/16 회의

5/17 회의

소감

김재희

데이터 분석 도구와 기술을 익히는 데 많은 시간이 걸렸습니다.
반복적인 테스트와 문제 해결 과정이 어려웠지만, 많이 성장할 수 있는 기회가 되었습니다.

복잡한 시계열 데이터를 정리하고 전처리하는 데 많은 시간이 걸려서
어려움을 느꼈지만, 좋은 경험이었다고 생각합니다.

이정호

이민형

프로젝트 초기에 명확한 요구사항을 정의하고 그에 맞춰 개발을 진행하는 것이 어려웠습니다.
특히, 시간과 자원에 제약을 받는 상황에서의 조율과 관리가 챌린지였습니다.

처음 진행해보는 프로젝트라서 데이터 수집부터 분석, 결과 해석까지
모든 단계에서 새로운 도전이었습니다.

황현숙

조은빈

팀원들의 다양한 의견을 조율하고 일정을 맞추는 과정이 어려웠습니다.
예상치 못한 문제와 변경 사항에 유연하게 대응하는 것이 큰 도전이었습니다.



Q&A



감사합니다

https://github.com/predicthunter/HV_project.git